

IA for Human For You

Marc THIERY, Rayis BERKAT, Nicolas MINEO, Mattias GERVILLIERS

2026

Sommaire

- .01 Contexte
- .02 Ethique
- .03 Nettoyage et préparation
- .04 Définition des modèles
- .05 Présentation des métriques
- .06 Cross validation
- .07 Analyse des résultats
- .08 Entrer une nouvelle donnée



Contexte - HumanForYou

Entreprise pharmaceutique - Inde - 4000 employés

- Retards projets :
- Coûts RH élevés
- Perte de productivité

15 % / an
Taux de rotation annuel des effectifs

~600 départs
Employés quittant l'entreprise chaque
année

Ethique

7 exigences recommandées par la Commission Européenne :

1) Autonomie humaine :

- L'IA ne prend jamais les décisions finales.
- Tâche revient aux responsables RH
- Elle reste un outil.

Ethique

7 exigences recommandées par la Commission Européenne :

2) Robustesse technique :

- Limiter la profondeur des modèles
- Gérer les valeurs manquantes
- Normaliser les données

Ethique

7 exigences recommandées par la Commission Européenne :

3) Confidentialité DPDPA :

- Supprimer les colonnes sensibles
- Transformer les données bruts en indicateurs synthétiques
- Supprimer les fichiers sources après extraction
- Limiter l'accès aux résultats au service RH

Ethique

7 exigences recommandées par la Commission Européenne :

4) Transparence:

- Chaque prédiction peut être expliquée
- Documentation (nettoyage, transformations)
- Entraînement des modèles

Ethique

7 exigences recommandées par la Commission Européenne :

5) Diversité & Équité :

- Gender → discrimination hommes / femmes
- Age → discrimination seniors / jeunes
- MaritalStatus → discrimination célibataire / mariée
- EducationField → certains domaines féminisés / masculinisés

Ethique

7 exigences recommandées par la Commission Européenne :

6) Bien être sociétal et environnemental :

- Pas de deep learning
- Améliorer les conditions de travail
- Réduire l'attrition naturelle

Ethique

7 exigences recommandées par la Commission Européenne :

7) Responsabilité :

- Définir qui est responsable légalement
- Conserver des logs en cas de problème
- Prévoir des mécanismes pour indemniser les personnes lésées

Nettoyage et préparation

Chargement des fichiers

Age	Attrition	BusinessTravel	Departement	Education
51	Yes	Travel_Frequently	Sales	2

general_data.csv

EmployeeId	EnvironmentSatisfaction	JobSatisfaction
1	3	4

employee_survey_data.csv
manager_survey_data.csv

EmployeeId	02/01/2015	05/01/2015
1	2015-01-02 09:43:45	2015-01-05 10:08:48

in_time.csv
out_time.csv

Nettoyage et préparation

Suppression de colonne

Age

Education

EducationField

Gender


MaritalStatus

EmployeeId


Over18

EmployeeCount


StandardHours



Biais Algorithmique



Overfitting



Bruit

Nettoyage et préparation

Fusion des fichiers

Age	Attrition	BusinessTravel	Departement	Education
51	Yes	Travel_Frequently	Sales	2


general_data.csv

EmployeeId	02/01/2015	05/01/2015
1	2015-01-02 09:43:45	2015-01-05 10:08:48

in_time.csv
out_time.csv

EmployeeId	EnvironmentSatisfaction	JobSatisfaction
1	3	4

employee_survey_data.csv
manager_survey_data.csv




AvgHoursPerDay	StdHoursPerDay	EnvironmentSatisfaction
7.0	1.0	3

general_dataframe
Pandas.DataFrame


Nettoyage et préparation

Préparation



Nettoyage et préparation

Préparation



Valeur manquante

Moyenne

Médiane

Mode

Constante


K plus proche voisins

Gestion des valeurs aberrante

Normalisation

Nettoyage et préparation

Préparation




Valeur manquante

Gestion des valeurs aberrante


Inter Quartile Range

Mesure la dispersion des données



Z score


mesure à quel point une valeur est éloignée de la moyenne, en nombre d'écart-types



Normalisation

Nettoyage et préparation

Préparation



Valeur manquante

Gestion des valeurs aberrante

Normalisation

StandardScaler

Moyenne de 0 et un écart-type de 1

RobustScaler

A partir de la médiane et l'écart interquartile

MaxAbsScaler

Comprime toutes tes données entre 0 et 1

MinMaxScaler

Divise chaque valeur par la valeur absolue maximale de la colonne entre -1 et 1


Définition des modèles

Régression logistique

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Chaque donnée à un poids associé

Le modèle calcule une combinaison




Si le résultat est proche de 1 $\rightarrow$ "oui"

Si le résultat est proche de 0 $\rightarrow$ "non"

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$


Définition des modèles

KNN (K-Nearest Neighbors)




Définition des modèles

KNN (K-Nearest Neighbors)




Définition des modèles

KNN (K-Nearest Neighbors)




Définition des modèles

KNN (K-Nearest Neighbors)



Définition des modèles

KNN (K-Nearest Neighbors)




Définition des modèles

Arbre de décision

$$\text{Gini Impurity} = 1 - \sum_i (p_i)^2$$

BusinessTravel	AvgHourPerDay	MonthlyIncome	Attrition
T_Frequently	7.5	88000	Oui
Non-Travel	7	34000	Non
Non-Travel	7.5	65000	Non
T_Frequently	9	40000	Oui
Non-Travel	8	18000	Oui
T_Rarely	8	23000	Non
T_Frequently	8.5	66500	Oui
T_Rarely	9	123000	Oui



Définition des modèles

RandomForest

BusinessTravel	AvgHourPerDay	MonthlyIncome	Attrition
T_Frequently	7.5	88000	Oui
Non-Travel	7	34000	Non
Non-Travel	7.5	65000	Non
T_Frequently	9	40000	Oui
Non-Travel	8	18000	Oui
T_Rarely	8	23000	Non
T_Frequently	8.5	66500	Oui
T_Rarely	9	123000	Oui

Bootstrapping

Créer des datasets aléatoires

De même taille que le dataset original

Feature

Choisir un sous nombre de variables

Construction des arbres

Aggregation

On regarde le résultat pour chaque arbre

Résultat le plus représentatif = résultat

Présentation des métriques - Accuracy

Taux global de bonnes prédictions du modèle

POURQUOI CETTE METRIQUE ?

Notre modèle doit classer chaque employé : reste ou part.

L'accuracy = sur l'ensemble des employés, combien le modèle a-t-il correctement classés ?

UTILITE DANS NOTRE PROJET

Permet de comparer rapidement nos différents algorithmes et éliminer les moins performants.

CALCUL

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{TN} + \text{FP} + \text{FN}}$$

Présentation des métriques - F1-score

Equilibre entre la détection des partants et la fiabilité des alertes

POURQUOI CETTE METRIQUE ?

Le F1-score combine deux dimensions clés :

- détecter le maximum de vrais partants
- ne pas déclencher trop de fausses alertes

CE QUE CA NOUS DIS ?

Score entre 0 et 1.

Plus il est proche de 1, meilleur est l'équilibre détection / précision

UTILITE DANS NOTRE PROJET

Le F1-score nous garantit que le modèle ne se contente pas d'ignorer la classe minoritaire pour gonfler son score

Présentation des métriques - ROC AUC

capacité du modèle à distinguer partants et non-partants, quel que soit le seuil

POURQUOI CETTE METRIQUE ?

Le ROC-AUC évalue le modèle sur tous les seuils possibles.

Il mesure sa capacité fondamentale à séparer les deux classes, indépendamment du réglage choisi.

UTILITE DANS NOTRE PROJET


Permet de valider que le modèle est réellement discriminant et pas juste chanceux.

CE QUE CA NOUS DIS ?

Plus la courbe est proche du coin en haut à gauche, meilleur est le modèle.




AUC Proche de 1 = très bon modèle
AUC proche de 0.5 = modèle inutile

Présentation des métriques - ROC AUC




Cross validation

K-Fold, Stratified K-Fold, Shuffle Split



→ Eviter le **sur-apprentissage** (overfitting)

On cherche le **sweet spot**



Analyse des résultats

Logistic Regression
0,2943

KNN
0,8721

Logistic Regression : Pas adapté

Decision Tree : Varie beaucoup


KNN : Très stable et bon en général

Random Forest : Robuste et stable

Decision Tree
0,7968

Random Forest
0,8766

Analyse des résultats



Entrer une nouvelle donnée

Marie Laurent :

- AvgHoursPerDay = 7.4
- TotalWorkingYears = 15
- MonthlyIncome = 83 000 ₹
- YearsAtCompany = 10
- DistanceFromHome = 5 km
- YearsWithCurrManager = 7
- PercentSalaryHike = 18%
- NumCompaniesWorked = 2
- StdHoursPerDay = 0.30
- EnvironmentSatisfaction = 4



L'employé reste

Entrer une nouvelle donnée

Ali Issa :

- AvgHoursPerDay = 9.7
- TotalWorkingYears = 5
- MonthlyIncome = 35 000 ₹
- YearsAtCompany = 1
- DistanceFromHome = 10 km
- YearsWithCurrManager = 1
- PercentSalaryHike = 14%
- NumCompaniesWorked = 2
- StdHoursPerDay = 0.34
- EnvironmentSatisfaction = 1

A solid red square graphic located on the right side of the slide.

L'employé part

Conclusion

→ Hyper paramètres

XGBoost, CatBoost, SVN



Streamlit

Interface web

The background is a solid blue color. There are several thin white lines: a horizontal line near the bottom, a vertical line slightly to the right of center, and two large, sweeping curves that intersect each other and the vertical line, creating a dynamic, abstract composition.

Merci pour votre attention

2026